

Aquí el speech completo, organizado por sección con lo que dices **antes** de correr el código y **después** de mostrar cada output:

Speech — Ayudantía 02: Acuífero Wolfcamp

Introducción

[Al abrir el script]

Buenas tardes a todos. En esta ayudantía vamos a trabajar con datos reales de un acuífero en Texas llamado Wolfcamp, que mide la carga piezométrica — esencialmente la presión del agua subterránea — en 85 pozos distribuidos en el territorio. El objetivo es recorrer el flujo completo de un análisis geoestadístico: desde la exploración visual, pasando por el variograma empírico, hasta el ajuste de modelos teóricos. Iremos parte por parte y en cada gráfico vamos a detenernos a discutir qué estamos viendo y qué implica para el análisis.

Setup

[Al cargar los datos]

Lo primero es cargar los datos. El dataset wolfcamp viene del paquete geoR y es un objeto de clase geodata, que es básicamente una lista. Si intentan hacer `as.data.frame(wolfcamp)` directamente no funciona bien, porque los componentes son heterogéneos — las coordenadas son una matriz y los datos son un vector. Por eso lo construimos manualmente, extrayendo `wolfcamp$coords` y `wolfcamp$data` por separado.

Parte a — antes de correr

Antes de calcular cualquier variograma, lo primero siempre es mirar los datos. Esto no es un detalle menor — si hay una tendencia espacial y la ignoramos, todo el análisis variográfico posterior va a estar contaminado. Lo que queremos evaluar acá es si el supuesto de estacionariedad de primer orden se cumple: ¿la media de la carga piezométrica es constante en todo el dominio, o cambia sistemáticamente según la ubicación? Corramos el gráfico y veamos.

Parte a — después del gráfico

¿Qué observan? Fíjense en el color y el tamaño de los puntos. Los puntos amarillos, que representan la mayor presión cercana a las 900 ft, están concentrados en la esquina inferior izquierda del gráfico — eso es el suroeste del dominio. Los puntos morados oscuros, de menor presión, están en la zona superior y derecha — el norte y noreste. Hay un gradiente visual claro de SW hacia NE.

¿Qué nos dice esto en términos estadísticos? Que $E[Z(s)]$ no es constante — la media depende de la ubicación. Entonces el supuesto de estacionariedad de primer orden no se cumple. Y esto tiene una consecuencia directa: si calculamos el variograma sobre los datos brutos, vamos a estar midiendo no solo la variabilidad del proceso aleatorio, sino también el efecto de ese gradiente. Lo veremos en la Parte b.

Parte b — antes de correr

Pasamos ahora al variograma empírico. El variograma $\gamma(h)$ mide cuánto se parecen en promedio dos observaciones separadas por una distancia h . El estimador de Matheron calcula eso promediando las diferencias al cuadrado de todos los pares que caen en una clase de distancia de ancho $width$. Vamos a calcular tres variogramas con distinto $width$ — 10, 30 y 60 km — para ver qué tan sensible es la estimación a ese parámetro.

Parte b — después del gráfico

Primero lo más importante: ¿alguno de los tres variogramas se aplanan en algún momento? No. Los tres siguen creciendo hasta los 150 km sin estabilizarse. Eso es exactamente lo que esperábamos dado lo que vimos en la Parte a — el gradiente de presión hace que a mayor distancia entre dos pozos, mayor sea la diferencia esperada, y eso nunca se detiene dentro del dominio. Un proceso estacionario produciría una curva que en algún momento deja de crecer y se queda horizontal — eso se llama sill. Aquí no hay sill.

Respecto al $width$: con 10 km ven que la curva es irregular, especialmente entre los 90 y 120 km — hay pocos pares de pozos tan separados, entonces la estimación es ruidosa. Con 60 km la curva es casi una línea recta — demasiado suave, pierde estructura. Con 30 km logramos un balance razonable, y es el que usaremos en las partes siguientes.

Parte c — antes de correr

Hasta ahora el variograma era omnidireccional: promediamos todos los pares sin importar en qué dirección apuntan. Pero ¿qué pasa si la dependencia espacial no es igual en todas las direcciones? Eso se llama anisotropía. Para detectarlo, vamos a calcular cuatro variogramas direccionales, restringiendo en cada caso los pares a los que apuntan aproximadamente hacia 0° , 45° , 90° y 135° . La convención es que 0° es Norte, 90° es Este, y así sucesivamente.

Una advertencia antes de ver el resultado: la formulación formal de la anisotropía geométrica — la razón de anisotropía, cómo corregirla transformando coordenadas — la verán el miércoles con el profesor. Hoy nos quedamos en la detección visual: ¿las cuatro curvas se comportan igual?

Parte c — después del gráfico

Claramente no se comportan igual. Miren la diferencia entre 45° y 135° . En la dirección 45° , que es noreste, el variograma crece muy pronunciadamente y no muestra ningún sill. ¿Por qué? Porque esa es exactamente la dirección del gradiente que vimos en la Parte a — al movernos hacia el NE cruzamos el gradiente completo, los pares tienen diferencias grandes.

Ahora miren la dirección 135° , que es la perpendicular — noroeste a sureste. Esa curva es mucho más plana y es la única que parece acercarse a un sill en algún momento. ¿Por qué? Porque al movernos en esa dirección vamos paralelos a las isolíneas de presión — como si camináramos a lo largo de una curva de nivel en un mapa topográfico. Los valores cambian poco, entonces los pares son más similares entre sí.

Esto es anisotropía: la continuidad espacial no es la misma en todas las direcciones. La dirección de mayor continuidad es 135° .

Parte d — antes de correr

El variograma empírico es ruidoso y no podemos usarlo directamente para predicción. Necesitamos ajustar un modelo paramétrico — una función matemáticamente válida — que capture esa estructura. Vamos a probar tres: el Exponencial, el Esférico y el Gaussiano. Los tres tienen los mismos parámetros principales — nugget, sill y range — pero difieren en cómo se comportan cerca del origen, y eso refleja qué tan suave o irregular es el proceso subyacente.

Un detalle importante: si intentamos ajustar estos modelos sobre el variograma de los datos originales, el algoritmo no converge — precisamente porque la curva sin sill no puede ser capturada por un modelo acotado. Eso en sí es una confirmación de la no estacionariedad. La solución es calcular el variograma removiendo la tendencia internamente con $\sim x + y$, que es lo que hacemos acá.

Parte d — después del gráfico y la tabla SSR

Vean el gráfico y la tabla juntos. El Gaussiano es el primero en descartarse — su SSR es 385.000, muy por encima de los otros dos. Visualmente también se nota: la curva verde alcanza el sill en apenas 30 km y deja todos los puntos de distancias grandes muy por encima. El Gaussiano supone un proceso infinitamente suave, y los datos del acuífero claramente no lo son.

Entre Exponencial y Esférico, el Esférico gana con SSR de 19.000 versus 30.000. La diferencia está en cómo cada uno describe el comportamiento cerca del origen — el Esférico captura mejor la curvatura real de los datos. En cuanto a los parámetros estimados: el nugget de $\sim 1.200 \text{ ft}^2$ refleja variabilidad a escalas menores que la distancia mínima entre pozos — puede ser variabilidad real a micro-escala o error de medición. El sill de $\sim 4.000\text{--}4.500 \text{ ft}^2$ es la varianza del proceso estacionario. Y el range de $\sim 100\text{--}150 \text{ km}$ indica que más allá de esa distancia, dos pozos son prácticamente independientes.

Parte e — antes de correr

Cerramos con la parte más importante desde el punto de vista conceptual. El modelo que subyace a todo esto es $Z(s) = \mu(s) + \varepsilon(s)$, donde $\mu(s)$ es la tendencia determinista y $\varepsilon(s)$ es el proceso estacionario. Si ajustamos un plano $\mu(s) = \beta_0 + \beta_1 X + \beta_2 Y$ y calculamos los residuos $\varepsilon(s) = Z(s) - \mu(s)$, esos residuos deberían ser estacionarios y su variograma debería mostrar un sill.

¿Por qué el variograma original crece indefinidamente? Si escriben la diferencia $Z(s+h) - Z(s)$, aparece el término $[\beta_1 \Delta x + \beta_2 \Delta y]$ que crece con la distancia. Al elevar al cuadrado y tomar esperanza, ese término crece cuadráticamente con $\|h\|$ y lleva el variograma a infinito. Al restar la tendencia, ese término desaparece.

Parte e — después del summary del modelo

El modelo ajustado es $\hat{Z}(s) = 607.77 - 1.278 \cdot X - 1.139 \cdot Y$. Los dos coeficientes son negativos y altamente significativos — $p < 2e-16$ en ambos casos. Eso significa que la

presión cae aproximadamente 1.28 ft por cada kilómetro hacia el Este, y 1.14 ft por cada kilómetro hacia el Norte. Consistente con el gradiente que vimos en la Parte a.

El R^2 es 0.891. Eso quiere decir que el simple plano lineal explica el 89% de la varianza total del dataset. Solo el 11% queda para el proceso estocástico $\varepsilon(s)$. La tendencia espacial dominaba completamente.

Parte e — después del gráfico comparativo

Este gráfico es el cierre natural de toda la ayudantía. La curva salmón es el variograma original — sigue creciendo hasta 25.000 ft² sin detenerse. La curva celeste es el variograma de los residuos — se estabiliza en ~4.000–4.500 ft² a partir de ~100 km. La escala cae en un factor de 6. Esa caída cuantifica exactamente cuánta varianza era atribuible a la tendencia y no al proceso estocástico.

Y lo más importante: el variograma de los residuos sí tiene sill. Eso confirma que $\varepsilon(s)$ es aproximadamente estacionario de segundo orden — el supuesto que necesitamos para que el modelo de variograma ajustado en la Parte d sea válido.

Cierre

En resumen, el flujo que recorrimos hoy es el estándar en geoestadística: primero explorar si hay tendencia, luego analizar el variograma omnidireccional y direccional para entender la estructura de dependencia espacial, luego ajustar un modelo teórico — siempre sobre residuos si hay tendencia — y finalmente verificar que la remoción de tendencia recuperó la estacionariedad. El miércoles el profesor va a formalizar la parte de anisotropía geométrica que dejamos en detección visual hoy. Cualquier duda, con gusto.

El speech está diseñado para que cada sección termine justo donde el siguiente bloque de código empieza, dándote un ritmo natural de *hablar* → *correr* → *comentar* → *hablar* → *correr*. ¿Lo ajusto en alguna parte?