

Speech — Ayudantía 05, Problema 2: Pipeline geoestadístico completo (Isla Rongelap)

Setup

(antes de correr) Cargamos el paquete geoR, que ya conocemos de sesiones anteriores, junto con tidyverse y patchwork. El dataset rongelap viene incluido en geoR y contiene 157 mediciones de radiación gamma en la isla Rongelap, en el Pacífico, contaminada por pruebas nucleares estadounidenses en los años 1950. Lo importante acá es que los datos no vienen listos para usar directamente: cada sitio registró los conteos de partículas durante un tiempo de exposición distinto, por lo que necesitamos normalizar. Construimos la tasa de radiación como $r(x_i) = \text{data} / \text{units.m}$, que nos da conteos por segundo. Esa será nuestra variable de interés para todo el análisis.

(después de correr) Tenemos 157 sitios en un dominio de aproximadamente 6.000 por 3.430 metros. La tasa varía entre 0.25 y 15.10 conteos por segundo, con media de 7.60. Hay bastante heterogeneidad, lo que ya nos anticipa que la estructura espacial va a ser interesante.

Parte a) Análisis exploratorio y tendencia espacial

(antes de correr — scatter) Lo primero que hacemos siempre es mirar los datos. Graficamos la ubicación de los 157 sitios coloreando por la tasa de radiación. Si existe algún gradiente espacial, los colores van a seguir una dirección — lo que nos diría que hay drift y que debemos trabajar con residuos en lugar de con la tasa directamente.

(después de correr — scatter) El mapa revela tres cosas importantes. Primero, la geometría de la isla es muy irregular: es una franja diagonal que va de suroeste a noreste, más un ramal al noreste. No es rectangular para nada, y eso va a afectar cómo interpretamos los mapas de kriging más adelante, porque la grilla de predicción sí va a ser rectangular. Segundo, sí hay un patrón espacial marcado: los valores más altos — amarillo intenso, hasta 15 ct/s — aparecen en dos clusters bien definidos, uno al noreste y otro dentro del extremo suroeste. La diagonal central tiene valores intermedios que aumentan suavemente de oeste a este. Tercero, el gradiente existe pero no es lineal limpio; hay mucha variabilidad local que un plano no va a capturar.

(antes de correr — lm) Ajustamos el modelo de tendencia lineal: $r(x) = \beta_0 + \beta_1 x + \beta_2 y$, por mínimos cuadrados ordinarios. Miramos el R^2 y los p-valores de los coeficientes para decidir si trabajamos con los residuos o directamente con la tasa.

(después de correr — lm) Los resultados son interesantes. β_1 — el coeficiente en x — tiene p-valor de 0.071, marginalmente significativo al 10% pero no al 5%. β_2 — en y — tiene p-valor de 0.967, completamente no significativo. El R^2 es 0.149: la tendencia lineal explica solo el 15% de la variabilidad total. Entonces, ¿con qué trabajamos? Decidimos quedarnos con los **residuos**, por tres razones: primero, garantiza estacionariedad en media; segundo, los residuos OLS tienen media exactamente cero, lo que va a ser clave para la Parte d cuando comparemos KS con KO; y tercero, dado que R^2 es bajo, el variograma de los residuos y de la tasa son prácticamente idénticos, así que la decisión no afecta sustancialmente el análisis variográfico.

Parte b) Variograma experimental y ajuste por mínimos cuadrados

(antes de correr — variograma base) Construimos el variograma experimental omnidireccional. El parámetro `max_dist` es el diámetro del dominio — unos 6.700 m — y usamos la mitad como cutoff, que es la regla práctica estándar. Fijamos 20 clases de distancia.

(después de correr — variograma base) El variograma tiene una forma claramente **no monótona**, que es lo primero que llama la atención. Tiene tres fases: crece desde $\gamma \approx 4.5$ en $h \approx 0$ hasta un pico de $\sim 9.2 \text{ ct}^2/\text{s}^2$ alrededor de $h \approx 882 \text{ m}$; luego **desciende** hasta $\gamma \approx 4.0$ cerca de $h \approx 1.750 \text{ m}$; y después oscila sin estabilizarse. Esto se llama **efecto hoyo**. ¿Por qué pasa? Porque los dos extremos de la isla tienen tasas parecidas entre sí (moderadas), mientras que los pares a $\sim 900 \text{ m}$ mezclan zonas de alta y baja contaminación — son los más heterogéneos. Noten también que el valor inicial ya es alto (~ 4.5), lo que anticipa un nugget importante.

(antes de correr — sensibilidad width) Ahora exploramos qué pasa cuando cambiamos el número de clases. Comparamos 10 clases (bins anchos), 20 (base) y 35 (bins estrechos).

(después de correr — sensibilidad width) Con pocas clases — $n=10$, azul — la curva es la más suave: el pico queda atenuado a ~ 8.3 porque se promedia con distancias adyacentes. Con muchas clases — $n=35$, verde — el pico sube a ~ 10.2 porque los bins son más "puros", pero para $h > 1.500 \text{ m}$ la curva oscila salvajemente entre 2.5 y 7.5, completamente inutilizable para ajuste de modelos. La configuración base $n=20$ en rojo captura bien el pico y mantiene estabilidad razonable. Punto clave: las tres

curvas **coinciden perfectamente en $h < 700$ m**, que es la zona más informada del variograma — hasta 1.200 pares por clase. El width afecta la nitidez del pico y la estabilidad a grandes lags, pero no la estructura a corta distancia.

(antes de correr — sensibilidad cutoff) Ahora variamos la distancia máxima: cutoff del 25%, 50% base, y 75% del diámetro.

(después de correr — sensibilidad cutoff) Con cutoff 25% — rojo — vemos la parte creciente hasta el pico pero no alcanzamos a ver si el variograma estabiliza. Con 75% — azul — descubrimos algo nuevo: para $h > 3.500$ m el variograma **sube de nuevo** hasta ~ 7.3 cerca de $h = 4.000$ m. Eso confirma que el efecto hoyo es oscilatorio, aunque con tan pocos pares en esas distancias puede ser también un artefacto estadístico. El cutoff 50% es el equilibrio correcto. Y para el ajuste paramétrico vamos a usar cutoff = 1.500 m, que es solo la región creciente monótona — así evitamos que el efecto hoyo distorsione los parámetros.

(antes de correr — variogramas direccionales) Los variogramas direccionales en 0° , 45° , 90° y 135° nos dicen si la correlación varía según la dirección — anisotropía geométrica.

(después de correr — variogramas direccionales) El resultado es inusual. La dirección 135° está directamente **ausente**: la isla es demasiado estrecha en esa dirección para generar pares suficientes. La dirección 0° — este-oeste — está **degenerada**: arranca con un valor negativo, matemáticamente imposible para un variograma válido, y salta inmediatamente a $\sim 14 \text{ ct}^2/\text{s}^2$ — la isla no tiene pares E-W porque corre en diagonal. Las direcciones 45° y 90° muestran curvas más razonables, con sills distintos: ~ 6.4 y $\sim 2.7 \text{ ct}^2/\text{s}^2$ respectivamente. Esa diferencia de sills entre direcciones es evidencia de **anisotropía geométrica fuerte**. Sin embargo, la calidad de las estimaciones es tan pobre para este dominio irregular que no vamos a modelar la anisotropía — procedemos con modelo isótropo, siendo conscientes de esta limitación.

(antes de correr — MCO/MCP) Ajustamos el modelo exponencial por MCO (weights="equal") y por MCP (weights="npairs") sobre el variograma con cutoff = 1.500 m. Recordemos: MCO da el mismo peso a todos los bins; MCP pondera por el número de pares de cada clase.

(después de correr — MCO/MCP) Del gráfico lo más llamativo es la diferencia en el nugget: MCO — azul — tiene un nugget considerablemente mayor que MCP — rojo. MCO con pesos iguales es arrastrado por los bins de $h > 700$ m, que tienen pocos pares pero valores extremos de ~ 10 -11, lo que eleva el nugget estimado. MCP en

cambio pondera más los bins cortos con hasta 668 pares, que tienen $\gamma \approx 4-6$, y obtiene un nugget más bajo y más fiel a esa región bien estimada. Ambas curvas alcanzan un sill similar de $\sim 7.5 \text{ ct}^2/\text{s}^2$, coherente con la varianza total de los residuos. Ninguna captura el pico en $h \approx 880 \text{ m}$ — el modelo exponencial es monótonamente creciente y satura antes del hoyo.

Parte c) Máxima Verosimilitud y selección de modelo

(antes de correr) `likfit()` maximiza la log-verosimilitud gaussiana del campo completo. A diferencia de MCO y MCP que usan solo el variograma empírico, MV incorpora toda la información del vector de datos simultáneamente. Comparamos modelo Exponencial y Esférico usando el AIC como criterio de selección — menor AIC significa mejor ajuste penalizado por complejidad.

(después de correr) El Exponencial obtiene $\text{AIC} = 738.86$ y el Esférico $\text{AIC} = 738.42$. El Esférico gana, pero la diferencia es **solo 0.44** — menor que 2, lo que en la práctica significa que los modelos son equivalentes. Elegimos el Esférico por interpretabilidad: su parámetro ϕ es el **rango real** donde la correlación cae exactamente a cero, más fácil de comunicar que el rango práctico del Exponencial.

Los parámetros estimados por MV son: $\sigma^2 = 1.83$, $\phi = 249 \text{ m}$, $\tau^2 = 4.72$, y $\mu_{\text{GLS}} = -0.248$. Noten que el nugget es **dominante**: $\tau^2/(\sigma^2 + \tau^2) \approx 72\%$ del sill total es nugget. Eso significa que la mayor parte de la variabilidad es no estructurada espacialmente — heterogeneidad a escala menor que la distancia mínima entre sitios. El rango de 249 m es muy corto respecto al dominio de 6.000 m. Y $\mu_{\text{GLS}} = -0.248$ difiere de cero porque GLS pondera por Σ^{-1} , a diferencia de OLS que da exactamente cero — esa diferencia va a ser el protagonista de la Parte e.

Parte d) Mapas de predicción KS y KO

(antes de correr) Construimos una grilla de 100×100 puntos sobre el bounding box del dominio. Para Kriging Simple usamos como "media conocida" el promedio aritmético de los residuos OLS, que es exactamente 0. Para Kriging Ordinario, la media es desconocida y se estima implícitamente vía la restricción $\sum \lambda_i = 1$. La diferencia entre $\mu_{\text{KS}} = 0$ y $\mu_{\text{GLS}} = -0.248$ va a ser clave en la siguiente parte.

(después de correr — mapas de predicción) Ambos mapas son casi idénticos visualmente. Lo primero que salta es que la mayor parte del rectángulo es **salmón uniforme** — el mar. En esas zonas no hay datos y la predicción colapsa rápidamente

hacia la media: KS hacia 0, KO hacia -0.248 . El rango del Esférico es $\phi = 249$ m, así que a más de 250 m de cualquier sitio la covarianza es exactamente cero — el predictor ya no tiene información local. Con un dominio de 6.000 m de largo, la enorme mayoría del mapa es fondo de media. A lo largo de la franja diagonal de la isla sí se aprecian los patrones: zonas amarillas de residuos positivos en los clusters NE y SW — tasas por sobre la tendencia — y zonas púrpuras intensas de residuos negativos en el tramo central. La predicción es extremadamente local: los manchones de color son pequeños y bien delimitados, consecuencia directa del nugget dominante y el rango corto.

(después de correr — mapas de varianza) Los mapas de varianza son muy reveladores. El fondo es **amarillo uniforme**, varianza máxima: ~ 6.3 para KS y ~ 6.6 para KO. A más de 249 m de cualquier sitio, $C(x_0, x_i) = 0$ y la varianza alcanza el sill total. La reducción de varianza ocurre solo a lo largo de la isla, y la varianza mínima de ~ 5.4 se alcanza en los dos clusters más densos. El rango $[5.4, 6.6]$ es estrecho y elevado — el piso lo impone el nugget $\tau^2 \approx 4.72$. Incluso encima de un sitio observado, la varianza no puede bajar de τ^2 porque ese nugget representa variabilidad irreducible a escala sub-muestral.

Hay dos propiedades fundamentales que vale la pena destacar acá. Primera: ¿por qué la varianza depende del diseño de muestreo y no de los valores observados? Porque $\sigma^2_{KS}(x_0) = C(0) - k^T \Sigma^{-1} k$ involucra solo distancias — dos conjuntos de datos con las mismas ubicaciones pero valores distintos tendrán mapas de varianza idénticos. Segunda: noten que KO tiene varianza ligeramente mayor que KS en el fondo — $\sigma^2_{KO} \geq \sigma^2_{KS}$ — que es exactamente el resultado teórico que demostraron en el Problema 1.

Parte e) Comparación de predictores

(antes de correr) Generamos el mapa de diferencias $Z^*_{KO} - Z^*_{KS}$. La teoría nos dice que cuando x_0 está cerca de los datos, ambos predictores convergen. Cuando está lejos, KS predice hacia $\mu_{KS} = 0$ y KO predice hacia $\mu_{GLS} = -0.248$ — la diferencia debería ser exactamente -0.248 en la zona sin datos.

(después de correr) El mapa es **completamente azul**: $KO < KS$ en absolutamente todo el dominio, sin excepción. El fondo marino es **azul oscuro uniforme** en toda zona alejada de los datos, con diferencia constante de -0.248 ct/s — exactamente $|\mu_{GLS} - \mu_{arit}|$. Todos esos puntos están fuera del rango del modelo y reciben idéntica influencia de la media. A lo largo de la isla, donde están los datos, aparecen

manchones blancos: la diferencia se acerca a 0 porque ambos predictores están anclados a los valores observados y la media tiene poco peso. Los clusters densos tienen los parches blancos más grandes — más sitios equivale a mayor radio de influencia. La transición de blanco a azul ocurre en ~249 m, el rango del Esférico.

¿Qué pasaría si usáramos $\mu_{\text{GLS}} = -0.248$ como media conocida en KS? Si $\mu_{\text{KS}} = \mu_{\text{GLS}}$, ambos predictores son teóricamente equivalentes — resultado que vimos en Ayudantía 04. El mapa sería completamente blanco. La única fuente de diferencia entre KO y KS en este análisis es esa constante $\mu_{\text{GLS}} - \mu_{\text{KS}} = -0.248$, y el mapa lo hace perfectamente visible.

Parte f) Validación cruzada leave-one-out

(antes de correr) `xvalid()` implementa LOO-CV en un solo llamado: para cada sitio x_i , retira la observación y predice su valor usando los 156 datos restantes, con los mismos parámetros θ estimados — sin re-estimar en cada iteración. Calculamos RMSE — el error de predicción promedio en unidades de la variable — y MSSE — el error cuadrático estandarizado por la varianza de kriging. Si el modelo está bien calibrado, MSSE debería ser ≈ 1 . Si $\text{MSSE} > 1$, el modelo subestima la incertidumbre; si $\text{MSSE} < 1$, la sobreestima.

(después de correr) $\text{RMSE} = 2.49 \text{ ct/s}$ y **MSSE = 1.019 ≈ 1** . El modelo está muy bien calibrado. El MSSE tan cercano a 1 confirma que la varianza de kriging predice correctamente la magnitud del error — el modelo sabe que es impreciso, y lo cuantifica bien. El RMSE parece grande — un 33% de la media — pero es consistente con $\sigma_{\text{KO}} \approx 2.3\text{--}2.6 \text{ ct/s}$ dado el nugget dominante. Es la naturaleza del dato: alta variabilidad local que el kriging no puede eliminar.

Del gráfico de diagnóstico, los errores se distribuyen simétricamente alrededor de cero sin sesgo sistemático — el error medio es $-0.013 \approx 0$. No hay heteroscedasticidad clara: la dispersión es homogénea en todo el rango de predichos. Hay dos outliers con errores extremos negativos — de -7.8 y -8.2 ct/s — que corresponden a sitios con residuos muy negativos, sin vecinos similares dentro de los 249 m de rango. Cuando se retira ese sitio, la predicción LOO sube hacia la media local y el error es enorme. Son los puntos aislados de baja radiación que vimos en el scatter inicial: con $\phi = 249 \text{ m}$, si un sitio atípico no tiene vecinos cercanos con valores similares, el kriging simplemente no puede predecirlo bien.

En síntesis: el modelo Esférico seleccionado por AIC, ajustado por MV con nugget dominante, describe adecuadamente la estructura espacial de la contaminación

gamma en Rongelap. El pipeline completo — EDA, variograma, estimación paramétrica, kriging y validación — funcionó consistentemente de principio a fin, y cada decisión de modelamiento quedó validada por los resultados numéricos y gráficos.